diff-gpt: авторегрессионное прогнозирование временных рядов с помощью токенизации производных и $\Sigma\Delta$-квантования

Михаил Борисов

18 апреля 2026 г.

Аннотация

Мы изучаем авторегрессионное прогнозирование непрерывных временных рядов decoder-only трансформером, обучаемым на токенизации на основе производных. Энкодер дифференцирует вход, масштабирует его по наблюдаемому диапазону и квантует $\Sigma\Delta$-модулятором первого порядка; декодер точно обращает эту процедуру с точностью до слагаемого порядка ширины словаря. Мы доказываем две оценки на уровне токенизации: достижимая кросс-энтропийная ошибка растёт как $\log V$, а ошибка реконструкции убывает как $1/V$ — обе независимо от модели. Дополнительно вводится порядковая кросс-энтропия с гауссовской мягкой меткой, превращающая классификацию по бинам в регрессию с учётом расстояния между бинами. На бенчмарке M4 Hourly порядковое сглаживание снижает sMAPE с 18,58 до 17,49 (6% относительного улучшения) без изменения архитектуры и расписания обучения.

1 Введение

Большинство современных моделей прогнозирования временных рядов — это регрессионные модели со специализированными индуктивными смещениями (patching, inverted attention, channel mixing). Они рассматривают выход как непрерывный вектор и минимизируют ℓ_2 или Huber-потерю. Большие языковые модели, напротив, суть decoder-only трансформеры, обучаемые кросс-энтропией над дискретным словарём. Вопрос, которым мы задаёмся: конкурентоспособен ли чистый LM-рецепт — фиксированная архитектура, фиксированная функция потерь, авторегрессионная генерация — на стандартных бенчмарках прогнозирования, если непрерывный вход предварительно отображён в точное дискретное представление.

Ключевым выбором является токенизация. Мы описываем энкодер на основе производной с $\Sigma\Delta$-квантованием первого порядка, обладающий двумя важными свойствами: (а) кросс-энтропийная ошибка на достижимом пределе масштабируется как $\log V$, поэтому размер словаря имеет предсказуемую информационную цену, и (б) ошибка реконструкции пары энкодер–декодер равномерно ограничена по длине последовательности величиной $\Delta/2 = D/(V-2)$, где D — максимальная наблюдаемая первая разность. Обе оценки представляют собой токенизационный контракт и справедливы независимо от модели.

Структура работы: раздел 2 описывает энкодер и декодер; раздел 3 доказывает две оценки; раздел 4 вводит порядковую мягкую кросс-энтропию и мотивирует её через оценку дифференциальной энтропии; раздел 5 приводит результаты на M4 Hourly и ETTh1.

2 Токенизация на основе производных

Пусть $x \in \mathbb{R}^{T\times F}$ — многомерный сигнал из F каналов длины T. Фиксируем порядок производной $k \geq 1$ (все результаты ниже — для $k = 1$); определяем $D_c = \max_t |x_{t+1,c} - x_{t,c}|$ поканально (*область определения*) и поканальный масштаб $s_c = (V-2)/(2D_c)$, где $V \in 2\mathbb{Z}_{\geq 2}$ — размер словаря.

2.1 Энкодер.

Для каждого канала энкодер вычисляет

$$
\begin{aligned}
y_t &= s \cdot (x_{t+1} - x_t), \qquad |y_t| \le (V-2)/2, && (1)\\
u_t &= \mathrm{trunc}(y_t) \in \mathbb{Z}, && (2)\\
e_t &= y_t - u_t, && (3)\\
E_t &= \textstyle\sum_{s \le t} e_s, \quad R_t = \mathrm{round}(E_t), \quad R_0 = 0, && (4)\\
c_t &= R_t - R_{t-1}, && (5)\\
q_t &= u_t + c_t + V/2 \quad \in \{0, \dots, V-1\}. && (6)
\end{aligned}
$$

Это $\Sigma\Delta$-модулятор первого порядка. Остаток от усечения e_t накапливается; когда накопитель пересекает $\pm\frac{1}{2}$, во следующий токен вкладывается единичный перенос $c_t \in \{-1, 0, +1\}$. Токены, выходящие за диапазон $[0, V-1]$ вследствие переноса, клиппируются; замечание 5 обсуждает этот эффект.

2.2 Декодер.

По начальному значению x_1 и последовательности токенов (q_t) декодер реконструирует

$$\hat{x}_{t+1} = \hat{x}_t + (q_t - V/2)/s, \qquad \hat{x}_1 = x_1. \tag{7}$$

3 Токенизационный контракт

Два утверждения на уровне токенизации, оба не зависят от модели.

3.1 Оценка реконструкции

Теорема 1 (реконструкция, $k = 1$)**.** *Для любого сигнала с* $D = \max_t |x_{t+1} - x_t| > 0$ *выполнено*

$$\|\hat{x} - x\|_\infty \;\le\; \frac{D}{V-2} \;=\; \frac{\Delta}{2}, \quad \textit{равномерно по } T. \tag{8}$$

Доказательство опирается на два элементарных факта о $\Sigma\Delta$-цикле.

Лемма 2. *Пусть* $\rho_t = E_t - R_t$. *Тогда* $\rho_0 = 0$ *и* $|\rho_t| \le \frac{1}{2}$ *для любого* t.

Доказательство. Непосредственно: R_t — округление E_t до ближайшего целого. □

Лемма 3 (сокращение на шаге)**.** $u_t + c_t = y_t + \rho_{t-1} - \rho_t$.

Доказательство. $c_t = R_t - R_{t-1} = (E_t - \rho_t) - (E_{t-1} - \rho_{t-1}) = e_t + \rho_{t-1} - \rho_t$. Прибавив к обеим сторонам u_t и используя $y_t = u_t + e_t$, получаем требуемое. □

Доказательство теоремы 1. Декодированный прирост равен $\hat{x}_{t+1} - \hat{x}_t = (q_t - V/2)/s = (u_t + c_t)\Delta$. Истинный прирост $x_{t+1} - x_t = y_t\Delta$. По лемме 3 их разность равна $(\rho_{t-1} - \rho_t)\Delta$. Суммируя от $t = 1$ до $T - 1$, получаем телескопическое сокращение:

$$\hat{x}_T - x_T \;=\; \Delta \sum_{t=1}^{T-1} (\rho_{t-1} - \rho_t) \;=\; \Delta\,(\rho_0 - \rho_{T-1}) \;=\; -\rho_{T-1}\,\Delta, \tag{9}$$

где использовано $\hat{x}_1 = x_1$ и $\rho_0 = 0$. По лемме 2 $|\rho_{T-1}| \le \frac{1}{2}$. Применив тот же аргумент к произвольному префиксу, получаем оценку, равномерную по t. □

Следствие 4 (масштабирование)**.** $\|\hat{x} - x\|_\infty = O(D/V)$. *Удвоение словаря уменьшает ошибку реконструкции в два раза.*

Замечание 5 (клиппирование). Поскольку $|y_t| \le (V-2)/2$ и $|c_t| \le 1$, имеем $q_t \in [0, V] \cup \{-1\}$. Насыщение на границе $\{-1, V\}$ клиппируется и вносит не более одного дополнительного Δ на клиппированный шаг. Так как $|y_t|$ достигает максимума лишь на конечном (как правило — пустом) множестве t, где ещё и направление переноса совпадает, суммарный эффект имеет порядок $O(\Delta)$ и поглощается в оценку скорости.

Замечание 6 (старшие производные). При $k \ge 2$ декодер применяет k интегрирований. $\Sigma\Delta$ первого порядка компенсирует одно из них; оставшиеся $k-1$ превращают ограниченный остаток в дрейф порядка $T^{k-1}\Delta/2$. Именно поэтому текущий энкодер использует $k = 1$. $\Sigma\Delta$-модулятор порядка k восстановил бы оценку $O(\Delta)$ ценой более сложного состояния.

3.2 Оценка кросс-энтропии

Пусть X_t — непрерывный прирост на шаге t при условии контекста ctx, с плотностью $p(\cdot \mid \mathrm{ctx})$ и дифференциальной энтропией $h(X_t \mid \mathrm{ctx}) = -\int p \log p$.

Предложение 7 (достижимая CE)**.** *В пределе тонкого квантования $\Delta \to 0$ кросс-энтропия оптимального авторегрессионного предиктора удовлетворяет*

$$\mathcal{L}^\star(V) \;=\; h(X_t \mid \mathrm{ctx}) + \log V - \log(2D) \;+\; o(1). \tag{10}$$

То есть $\mathcal{L}^\star$ линейна по $\log V$ с угловым коэффициентом 1.

Набросок. Стандартное соотношение между дискретной и дифференциальной энтропией: при плотности p и ширине ячейки Δ

$$H(\mathrm{bin}) = -\sum_b P(\mathrm{bin}{=}b) \log P(\mathrm{bin}{=}b) = h(X) - \log \Delta + o(1) \qquad (\Delta \to 0). \tag{11}$$

(См., напр., Cover & Thomas, *Elements of Information Theory*, §8.3.) Условная версия заменяет X на $X \mid \mathrm{ctx}$. Подставляя $\Delta = 2D/(V-2)$, получаем приведённую формулу. □

Следствие 8 (инвариантная по словарю метрика мастерства)**.** *Модели при $V_1 \ne V_2$ сопоставимы только через* остаток дифференциальной энтропии

$$\tilde{h}(V) := \mathcal{L}(V) - \log V + \log(2D), \tag{12}$$

который оценивает $h(X_t \mid \mathrm{ctx})$ и в пределе не зависит от V.

3.3 Эмпирическая проверка

На ETTh1 при seq_len = 96, pred_len = 96, 2000 итераций:

V	val CE (nats)	$\log V$	$\mathcal{L}(V) - \log V$
256	3,96	5,545	−1,585
64	2,51	4,159	−1,649

Предсказанная разница $\log(256/64) = 1{,}386$ нат согласуется с наблюдаемой 1,45 нат с точностью до 0,06 — последнее представляет собой остаток $\tilde{h}$. Это согласуется с предложением 7.

4 Порядковая мягкая кросс-энтропия

Стандартная кросс-энтропия рассматривает V бинов как номинальные категории: прогноз, ошибающийся на один бин, штрафуется так же, как прогноз, ошибающийся на пятьдесят. Это ложь: бины — порядковый индекс над непрерывной шкалой, и "ошибка на один бин" почти верна.

Заменяем one-hot цель $\mathbf{1}_{i=y}$ на дискретную гауссиану по индексам бинов:

$$p_i^{\text{soft}}(y;\sigma) \;\propto\; \exp\!\left(-\tfrac{(i-y)^2}{2\sigma^2}\right), \qquad \sigma \geq 0, \tag{13}$$

и обучаем стандартной мягкой кросс-энтропией $\mathcal{L}_\sigma = -\sum_i p_i^{\text{soft}} \log q_i$, где $q = \text{softmax}(\text{logits})$. При $\sigma \to 0$ восстанавливается обычная кросс-энтропия с one-hot целью.

Почему это важно для ΣΔ-квантованного сигнала. Непрерывное значение, попавшее вблизи границы бина, с точностью до переноса относится к одному из двух соседних бинов. ΣΔ-энкодер может сдвинуть его в любую сторону в зависимости от накопителя. Обучение с one-hot целью делает вид, что это назначение детерминировано; мягкая цель признаёт по существу стохастическое разрешение равенства. В более общем случае любая алеаторная компонента $p(X \mid \text{ctx})$ делает истинное условное распределение по бинам и так гладким, похожим на гауссиану, и label smoothing с масштабом σ *в единицах бина* — это порядковый эквивалент подгонки под это распределение.

Бин-пространство против шкалы значений. Так как ширина бина $\Delta = 2D/V$, постоянное сглаживание в шкале значений $\sigma_{\text{val}} = \sigma \cdot \Delta$ требует, чтобы σ росло *линейно по* V. Величина σ, подобранная при $V = 64$, окажется заниженной в 4 раза при $V = 256$.

5 Эксперименты

5.1 M4 Hourly (краткосрочный, глобальный)

Протокол M4: поканальная z-нормировка, одна глобальная модель, обученная по всем 414 Hourly-рядам, горизонт $H = 48$. Модель: 2-слойный GPT, $d = 64$, $h = 4$, $V = 256$, 20k итераций, AdamW, восстановление best-val чекпоинта. Метрика: sMAPE (меньше — лучше).

потеря	sMAPE	MASE
обычная CE ($\sigma = 0$)	18,58	–
мягкая CE $\sigma = 1.0$	17,55	1,663
мягкая CE $\sigma = 2.0$	**17,49**	**1,659**
мягкая CE $\sigma = 3.0$	17,35	1,949

$\sigma = 2$ — совместный оптимум по обеим метрикам. При $\sigma = 3$ sMAPE продолжает улучшаться, но MASE резко ухудшается — классический признак пере-сглаживания, когда прогнозы стягиваются к условному среднему, что выгодно для симметричного sMAPE, но проигрывает под наивно-сезонной нормировкой MASE. Выигрыш в один пункт sMAPE при $\sigma = 1.0$ по сравнению с обычной CE — ключевой качественный вывод: *на короткогоризонтном бенчмарке с множеством коротких разнородных рядов сказать модели "ошибиться на один бин почти не ошибка" стоит столько же, сколько заметное архитектурное изменение.*

5.2 ETTh1 (долгосрочный, многоканальный)

Протокол iTransformer: 7 каналов, seq_len = 96, pred_len = 96, хронологический раздел 12/4/4 месяца, StandardScaler по train. Одна модель при $d = 128$, $h = 4$, 2 слоя, 2000 итераций, batch 32, AdamW.

конфигурация	MSE	MAE
$V = 256$, обычная CE	0,9861	0,6056
$V = 64$, обычная CE	0,9787	0,6030
$V = 64$, мягкая CE $\sigma = 1.0$	0,9806	0,6034

ETTh1 упирается в потолок по ёмкости / подгонке на уровне MSE $\approx 0{,}98$: и уменьшение словаря, и мягкие цели двигают результат в пределах шума. Контраст с M4 наводит на мысль, что *ценность* мягких целей сосредоточена в режиме нехватки данных, когда множество коротких рядов вынуждает модель экстраполировать условные распределения без достаточного сигнала, чтобы локализовать конкретный бин.

5.3 Сводка по масштабированию словаря и функции потерь

Бюджет токенизации против бюджета потерь:

	на удвоение словаря	режим
идеальная CE $\mathcal{L}^\star(V)$	$+\log 2 \approx 0{,}69$ нат	предл. 7
реконструкция $\|\hat{x} - x\|_\infty$	$\times \frac{1}{2}$	теор. 1
порядковое сглаживание $\sigma^\star$	$\times 2$ (сохранение в шкале значений)	§4

6 Связанные работы

Инвертированные трансформеры и channel-mixing. iTransformer [1] и PatchTST [2] отказываются от авторегрессионной головы и регрессируют весь горизонт за один проход — доминирующая схема на долгогоризонтных бенчмарках. Наша модель оставляет рецепт GPT неизменным; индуктивное смещение переносится на токенизацию.

Порядковая классификация и label smoothing. Label smoothing [3] равномерно распределяет вероятность по нецелевым классам. Варианты со взвешиванием по расстоянию (cumulative link models, ordinal softmax) встречаются в литературе по порядковой регрессии. Гауссовские мягкие цели появляются, в частности, в CORAL [4] и в score-matching диффузионных моделей для дискретных целей [5]. Наш вклад — привязка масштаба сглаживания σ к токенизации на основе $\Sigma\Delta$-энкодера.

$\Sigma\Delta$-квантование. $\Sigma\Delta$-модуляторы первого порядка — классический элемент АЦП [6]; мы применяем их как недифференцируемый шаг предобработки перед трансформером.

7 Заключение

Decoder-only трансформер, авторегрессионно обученный на токенах производной с $\Sigma\Delta$-квантованием, достигает конкурентных результатов в краткосрочном и долгосрочном прогнозировании без специализированной головы. Токенизационный контракт даёт два замкнутых закона масштабирования словаря; порядковая мягкая кросс-энтропия согласована с естественной геометрией по бинам и приносит относительное улучшение sMAPE на 6% на M4 Hourly без изменения архитектуры.

Список литературы

[1] Liu, Y. et al. *iTransformer: Inverted Transformers are Effective for Time Series Forecasting.* ICLR 2024. arXiv:2310.06625.

[2] Nie, Y. et al. *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers.* ICLR 2023.

[3] Szegedy, C. et al. *Rethinking the Inception Architecture for Computer Vision.* CVPR 2016.

[4] Cao, W., Mirjalili, V., Raschka, S. *Rank-consistent Ordinal Regression for Neural Networks with Application to Age Estimation.* Pattern Recognition Letters 2020.

[5] Austin, J. et al. *Structured Denoising Diffusion Models in Discrete State-Spaces.* NeurIPS 2021.

[6] Candy, J.C., Temes, G.C. *Oversampling Delta-Sigma Data Converters.* IEEE Press 1992.