diff-gpt: авторегрессионное прогнозирование временных рядов с помощью токенизации производных и MASH $\Sigma\Delta$-квантования

18 апреля 2026 г.

Аннотация

Мы изучаем авторегрессионное прогнозирование непрерывных временных рядов decoder-only трансформером, обучаемым на токенизации на основе производных. Энкодер дифференцирует вход до порядка $k \geq 1$, масштабирует его по наблюдаемому диапазону и квантует $MASH$-модулятором (multi-stage noise-shaping, многокаскадный $\Sigma\Delta$-модулятор) порядка k; декодер обращает эту процедуру. Мы доказываем две не зависящие от модели оценки на уровне токенизации: достижимая кросс-энтропийная ошибка растёт линейно по $\log V$, а ошибка реконструкции равномерно ограничена величиной $\Delta/2 = D/(V - 2 - 2^k)$ для любого k, удовлетворяющего условию $V > 2^k + 2$. Далее мы наблюдаем, что, хотя оценка реконструкции MASH точна для чистого шума квантования, *ошибка предсказания* модели растёт как $O(\Delta \cdot T^{k-1})$ после k интегрирований декодера, что даёт принципиальную причину предпочитать $k = 1$ для прогнозирования, несмотря на аккуратную теорию высших порядков. Вводится порядковая кросс-энтропия с гауссовской мягкой меткой, превращающая классификацию по бинам в регрессию с учётом расстояния между бинами; на M4 Hourly она снижает sMAPE с 18,58 до 17,49 (относительное улучшение на 6%) без изменения архитектуры.

1 Введение

Большинство современных моделей прогнозирования временных рядов — это регрессионные модели со специализированными индуктивными смещениями (patching, inverted attention, channel mixing), обучаемые минимизацией ℓ_2- или Huber-функции потерь. Большие языковые модели, напротив, являются decoder-only трансформерами, обучаемыми кросс-энтропией над дискретным словарём. Наш вопрос: конкурентоспособен ли чистый LM-рецепт — фиксированная архитектура, фиксированная функция потерь, авторегрессионная генерация — на стандартных бенчмарках при условии точного дискретного представления непрерывного входа.

Ключевой выбор — токенизация. Мы описываем энкодер на основе производной с MASH $\Sigma\Delta$-квантованием, удовлетворяющий двум замкнутым законам масштабирования словаря: (а) идеальная кросс-энтропийная ошибка линейна по $\log V$ (предл. 7) и (б) ошибка реконструкции равномерно ограничена по T величиной $\Delta/2$ для любого порядка k (теор. 1). Обе оценки на уровне токенизации — они справедливы независимо от модели.

Структура работы. Раздел 2 описывает энкодер и декодер; раздел 3 доказывает две оценки и предупреждает, что точная оценка теоремы реконструкции справедлива только для шума квантования, тогда как ошибка предсказания модели при больших k ведёт себя хуже; раздел 4 вводит порядковую мягкую кросс-энтропию; раздел 5 приводит результаты на M4 Hourly и ETTh1.

2 Токенизация на основе производных

Пусть $x \in \mathbb{R}^{T\times F}$ — многомерный сигнал из F каналов длины T. Фиксируем порядок производной $k \geq 1$ и определяем $D_c = \max_t |x_{t+1,c} - x_{t,c}|$ поканально (область определения). Для чётного V с $V > 2^k + 2$ определяем поканальный масштаб

$$s_c \;=\; \frac{V-2-2^k}{2D_c}, \qquad \Delta_c \;=\; \frac{1}{s_c} \;=\; \frac{2D_c}{V-2-2^k}. \tag{1}$$

Запас 2^k — это максимальный выброс, который MASH может произвести сверх исходного входа (лемма 2); без него квантователь насыщался бы на пиках сигнала и терял гарантию формирования шума (noise-shaping).

2.1 MASH-модулятор порядка k.

Каждый из k каскадов — стабильный $\Sigma\Delta$-цикл первого порядка. Каскад 1 работает с масштабированной k-й конечной разностью $y_t = s \cdot \Delta^k x_t$; каскад $i \geq 2$ работает с $-\varepsilon_t^{(i-1)}$, ошибкой квантования предыдущего каскада (ограниченной $\frac{1}{2}$ в единицах бина). Пусть $q_t^{(i)}$ — целочисленный выход каскада i, $\varepsilon_t^{(i)} = q_t^{(i)} -$ (вход квантователя каскада i).

Итоговый поток токенов — цифровая дифференциаторная комбинация

$$q_t \;=\; \sum_{i=0}^{k-1} (1-z^{-1})^i \, q_t^{(i+1)} \;=\; q_t^{(1)} + \Delta q_t^{(2)} + \Delta^2 q_t^{(3)} + \cdots + \Delta^{k-1} q_t^{(k)}, \tag{2}$$

со сдвигом на $V/2$ и обрезанием в диапазон $\{0, \ldots, V-1\}$.

2.2 Декодер.

По стартовому префиксу $(x_1, \ldots, x_k)$ и последовательности токенов (q_t) декодер реконструирует сигнал, деквантуя и интегрируя k раз:

$$\hat{x}_{t+1} \;=\; \hat{x}_t + (q_t - V/2)\,\Delta. \tag{3}$$

2.3 Поканальные порядки.

Для многомерного входа, где каналы имеют качественно разную динамику (например, столбец с медленным дрейфом тренда рядом со столбцом стационарного шума), общий k неоптимален. Реализация позволяет задавать k в виде поканального вектора k_c вместо скаляра. Каждый канал дифференцируется до своего k_c, масштабируется коэффициентом $(V-2-2^{k_c})/(2D_c)$ при $k_c \geq 2$ (для запаса под MASH) или $(V-2)/(2D_c)$ иначе, затем поканально проходит через соответствующий вариант $\Sigma\Delta$ (простое округление при $k_c = 0$, схема с переносом при $k_c = 1$, MASH при $k_c \geq 2$). Энкодер выравнивает все каналы по общему окну длины $T - \max_c k_c$, сохраняет сырой префикс в $start$, а декодер восстанавливает каждый канал, применяя к нему k_c накопительных сумм. Теорема 1 и предл. 7 применимы поканально с заменой скалярных D и k на D_c и k_c.

3 Токенизационный контракт

Два утверждения на уровне токенизации, не зависящие от модели.

3.1 Оценка реконструкции

Теорема 1 (реконструкция MASH, любой k)**.** *Для любого сигнала с $D = \max_t |\Delta^k x_t| > 0$ и любого размера словаря $V > 2^k + 2$ пара энкодер-декодер MASH удовлетворяет*

$$\|\hat{x} - x\|_\infty \;\le\; \frac{D}{V - 2 - 2^k} \;=\; \frac{\Delta}{2}, \qquad \text{равномерно по } T. \tag{4}$$

Доказательство опирается на стандартное тождество для каскада.

Лемма 2 (формирование шума MASH)**.** *Пусть $\varepsilon_k := \varepsilon^{(k)}$ — ошибка квантования последнего каскада. Суммарный выход* (2) *удовлетворяет*

$$q_t - y_t \;=\; (1 - z^{-1})^k\, \varepsilon_{k,t}, \qquad |\varepsilon_{k,t}| \;\le\; \tfrac{1}{2}. \tag{5}$$

Набросок. Индукция по каскадам. $\Sigma\Delta$ первого порядка для каскада 1 даёт $q_t^{(1)} = y_t + \Delta\varepsilon_t^{(1)}$. Каскад $i \ge 2$ с входом $-\varepsilon_t^{(i-1)}$ даёт $q_t^{(i)} = -\varepsilon_t^{(i-1)} + \Delta\varepsilon_t^{(i)}$. Подставляя в (2) и телескопически сворачивая промежуточные $\varepsilon^{(i)}$, получаем $q_t = y_t + \Delta^k\varepsilon_{k,t}$. Оценка $|\varepsilon_{k,t}| \le 1/2$ непосредственно следует из округления к ближайшему целому на каждом каскаде. □

Лемма 3 (ограниченность выхода MASH)**.** $|q_t - y_t| \le 2^{k-1}$.

Доказательство. $|\Delta^k\varepsilon_k| \le \|(1 - z^{-1})^k\|_1 \cdot \max|\varepsilon_k| = 2^k \cdot \frac{1}{2} = 2^{k-1}$. □

Запас 2^k в знаменателе масштаба гарантирует, что этот выброс останется в диапазоне квантователя и не приведёт к насыщению.

Доказательство теоремы 1. Декодированный прирост равен $(q_t - V/2)\Delta = (y_t + \Delta^k\varepsilon_{k,t})\Delta$. Истинный прирост равен $y_t\Delta$. Их разность равна $\Delta^k\varepsilon_{k,t}\cdot\Delta$. k-кратное суммирование, начиная с точных начальных значений, телескопически сворачивает Δ^k до $\varepsilon_{k,t}$:

$$\hat{x}_T - x_T \;=\; \varepsilon_{k,T-k} \cdot \Delta. \tag{6}$$

По лемме 2, $|\varepsilon_k| \le \frac{1}{2}$, откуда $|\hat{x}_T - x_T| \le \Delta/2$. □

Следствие 4 (масштабирование)**.** $\|\hat{x} - x\|_\infty = O(D/V)$. *Удвоение словаря уменьшает ошибку реконструкции в два раза, равномерно по T и для любого k.*

3.2 Ошибка предсказания против квантовального шума

Теорема 1 ограничивает разницу между $\hat{x}$ и x *при условии* идеального прохождения пары энкодер–декодер. При авторегрессионном прогнозировании декодер потребляет не точные закодированные токены истинного сигнала, а токены, *предсказанные* моделью, несущие ошибку предсказания в дополнение к шуму квантования.

Предложение 5 (усиление ошибки предсказания при порядке k)**.** *Пусть типичная величина ошибки предсказания модели — η бинов (т.е. $\eta \cdot \Delta$ в шкале значений на шаг). После k интегрирований декодера ошибка прогноза в конце горизонта растёт как*

$$|\hat{x}_{T+H} - x_{T+H}| \;=\; O\Big(\eta \cdot \Delta \cdot H^{\,k-1}\Big), \tag{7}$$

где H — число шагов прогноза.

Набросок. Ошибка предсказания токена δq_t типичной величины η входит в декодер как ошибка оценки производной $\delta q_t \cdot \Delta$. После k последовательных операций накопительной суммы последовательность смещений размера $\eta\Delta$ (сонаправленных или случайных) порождает выход, величина которого на шаге H растёт как $\eta\Delta H^{k-1}$ (интегрирование полинома по H). □

Замечание 6 ($k = 1$ предпочтителен для прогнозирования). При $k = 1$ коэффициент усиления $H^0 = 1$: ошибки предсказания вносят вклад пропорционально размеру бина, без мультипликативного усиления по горизонту. При $k = 2$ однобинная ошибка токена растёт как $H \cdot \Delta$: на 48-шаговом горизонте это порядка 24Δ — намного больше границы $\Delta/2$ для шума квантования. Эмпирически (раздел 5) это проявляется как катастрофическая регрессия прогноза при $k = 2$, несмотря на строго меньшую кросс-энтропию на уровне токенов.

3.3 Оценка кросс-энтропии

Пусть X_t — непрерывный прирост на шаге t при условии контекста ctx, с плотностью $p(\cdot \mid \mathrm{ctx})$ и дифференциальной энтропией $h(X_t \mid \mathrm{ctx}) = -\int p \log p$.

Предложение 7 (достижимая CE). *В пределе мелкого квантования $\Delta \to 0$ кросс-энтропия оптимального авторегрессионного предиктора удовлетворяет*

$$\mathcal{L}^\star(V) \;=\; h(X_t \mid \mathrm{ctx}) + \log V - \log(2D) \;+\; o(1). \tag{8}$$

То есть $\mathcal{L}^\star$ линейна по $\log V$ с угловым коэффициентом 1.

Набросок. Стандартное соотношение между дискретной и дифференциальной энтропией (Cover & Thomas, §8.3):

$$H(\mathrm{bin}) = h(X) - \log \Delta + o(1), \qquad \Delta \to 0. \tag{9}$$

Условная версия заменяет X на $X \mid \mathrm{ctx}$. Подставляя $\Delta = 2D/(V - 2 - 2^k) \sim 2D/V$, получаем требуемое. □

Следствие 8 (инвариантная по словарю метрика мастерства). *Модели при $V_1 \neq V_2$ сопоставимы только через остаток дифференциальной энтропии*

$$\tilde{h}(V) := \mathcal{L}(V) - \log V + \log(2D), \tag{10}$$

который оценивает $h(X_t \mid \mathrm{ctx})$ и в пределе не зависит от V.

3.4 Эмпирическая проверка

M4 Hourly, глобальная модель, развёртка по V с σ, масштабируемым $\propto V$ для сохранения сглаживания в шкале значений:

V	σ	val CE (nats)	$\Delta \log V$	Δ(CE)
64	0.5	1,01	—	—
128	1.0	1,70	$\log 2 = 0{,}69$	0,69
256	2.0	2,35	$\log 2 = 0{,}69$	0,65
512	4.0	3,04	$\log 2 = 0{,}69$	0,69

Эмпирические приросты CE совпадают с $\log 2$ при каждом удвоении словаря с точностью до 0,04 нат. Согласуется с предл. 7.

4 Порядковая мягкая кросс-энтропия

Стандартная кросс-энтропия рассматривает V бинов как номинальные категории: прогноз, ошибающийся на один бин, штрафуется так же, как прогноз, ошибающийся на пятьдесят. Но бины — это порядковый индекс на непрерывной шкале, и «ошибка на один бин» почти верна.

Заменяем one-hot цель $\mathbf{1}_{i=y}$ на дискретную гауссиану:

$$p_i^{\text{soft}}(y;\sigma) \;\propto\; \exp\!\left(-\tfrac{(i-y)^2}{2\sigma^2}\right), \qquad \sigma \geq 0, \tag{11}$$

и обучаем мягкой кросс-энтропией $\mathcal{L}_\sigma = -\sum_i p_i^{\text{soft}} \log q_i$. При $\sigma \to 0$ восстанавливается обычная CE.

Почему это важно для $\Sigma\Delta$-квантованного сигнала. Непрерывное значение, попавшее вблизи границы бина, с точностью до MASH-переноса относится к одному из двух соседних бинов. Обучение с one-hot-целью делает вид, что это назначение детерминировано; мягкая цель признаёт стохастическое разрешение равенства. В общем случае любая алеаторная компонента $p(X \mid \text{ctx})$ делает истинное условное распределение гладким; label smoothing с масштабом σ в единицах бина — порядковый эквивалент.

Бин-пространство против шкалы значений. Так как $\Delta \approx 2D/V$, постоянное сглаживание в шкале значений $\sigma_{\text{val}} = \sigma \cdot \Delta$ требует, чтобы σ росла линейно по V.

5 Эксперименты

5.1 M4 Hourly, краткосрочный глобальный протокол

Протокол M4: поканальная z-нормировка, одна глобальная модель по всем 414 Hourly-рядам, горизонт $H = 48$, восстановление лучшего по валидации чекпоинта. Модель: 2-слойный GPT, $d_{\text{model}} = 64$, $h = 4$, блок 138, 20k итераций, AdamW, argmax при $T = 0$ на выводе.

Развёртка soft-CE при $V = 256$.

σ	sMAPE	MASE
0 (обычная CE)	18,58	—
1,0	17,55	1,663
2,0	**17,49**	**1,659**
3,0	17,35	1,949

$\sigma = 2$ — совместный оптимум. При $\sigma = 3$ sMAPE продолжает улучшаться, но MASE резко ухудшается — классический признак пересглаживания.

Развёртка словаря (U-образная).

V	σ	sMAPE	MASE
64	0,5	19,96	2,019
128	1,0	19,39	1,888
256	**2,0**	**17,49**	**1,659**
512	4,0	18,21	1,772

Немонотонная зависимость с внутренним оптимумом при $V = 256$. Меньший V хуже по точности реконструкции; больший V чрезмерно квантует при ~ 280k обучающих токенов. CE-оценка всегда точна ($\log 2$ при каждом удвоении), а кривая качества прогноза — нет.

Аблация порядка производной.

k	val CE	sMAPE	MASE	примечание
1	**2,35**	**17,49**	**1,66**	—
2	2,28	39,27	8,93	усиление ошибки предсказания

Обучающая потеря на уровне токенов *ниже* при $k = 2$, что подтверждает обучаемость токенизации высшего порядка MASH. Но реконструкция через двойное интегрирование линейно усиливает ошибку предсказания по горизонту (предл. 5), обрушивая sMAPE. На практике для авторегрессионного прогнозирования предпочтителен $k = 1$.

Чувствительность к размеру модели ($V = 256$, $\sigma = 2$).

d_{model}	n_{layer}	параметры	val CE	sMAPE	MASE
32	2	∼30k	2,36	18,47	1,88
64	**2**	∼130k	2,35	**17,49**	**1,66**
64	4	∼260k	2,35	17,41	1,68
128	2	∼400k	2,38	18,67	1,99

При ~ 280k обучающих токенов конфигурация 64×2 (~ 2 токена на параметр) находится близко к потолку при данном бюджете данных.

5.2 ETTh1, долгосрочный многоканальный протокол

Протокол iTransformer: 7 каналов, seq_len = 96, pred_len = 96, хронологическое разбиение 12/4/4 месяца. Одна модель с $d = 128$, $h = 4$, $n_{\text{layer}} = 2$, 2000 итераций, batch 32.

конфигурация	MSE	MAE
$V = 256$, обычная CE	0,9861	0,6056
$V = 64$, обычная CE	0,9787	0,6030
$V = 64$, мягкая CE $\sigma = 1{,}0$	0,9806	0,6034

ETTh1 упирается в потолок MSE $\approx 0{,}98$. Контраст с M4 наводит на мысль, что ценность мягких целей сосредоточена в режиме нехватки данных, когда множество коротких рядов вынуждает модель экстраполировать условные распределения без достаточного сигнала для локализации бина.

5.3 Сводка по масштабированию словаря и потерь

	на удвоение словаря	ссылка
идеальная CE $\mathcal{L}^\star(V)$	$+\log 2 \approx 0{,}69$ нат	предл. 7
реконструкция $\lVert\hat{x} - x\rVert_\infty$	$\times \frac{1}{2}$	теор. 1
порядковое сглаживание $\sigma^\star$	$\times 2$ (сохранение в шкале значений)	§4

6 Связанные работы

Инвертированные и channel-mixing трансформеры. iTransformer [1] и PatchTST [2] отказываются от авторегрессионной головы и предсказывают весь горизонт за один проход. Наша модель оставляет рецепт GPT неизменным; индуктивное смещение переносится в токенизацию.

Порядковая классификация и label smoothing. Label smoothing [3] равномерно распределяет вероятность по нецелевым классам. Дистанционно-взвешенные варианты существуют в литературе по порядковой регрессии; гауссовские мягкие цели — в CORAL [4] и в score-matching диффузионных моделей для дискретных целей [5].

$\Sigma\Delta$-квантование. $\Sigma\Delta$-модуляторы первого порядка — классический элемент АЦП [6]; MASH обобщает их на произвольный порядок с гарантированной стабильностью [7]. Мы применяем MASH как недифференцируемый шаг предобработки перед языковой моделью.

7 Направления будущих исследований

Эксперименты выше сосредоточены на детерминированных sMAPE/MSE-бенчмарках. Архитектурные решения diff-gpt — авторегрессионный LM-рецепт над квантованным словарём — дают структурные преимущества в другом режиме, заслуживающем отдельного продолжения.

Вероятностное прогнозирование (квантили, доверительные интервалы). Декодер выдаёт полное распределение над токенами на каждом шаге; N-выборочные прогоны дают нативные оценки P10/P50/P90 без pinball-функции потерь или отдельной quantile-regression-головы. Прямые конкуренты (iTransformer, N-BEATS) оптимизируют MSE, то есть условное среднее. Домены: диспетчеризация энергетической нагрузки с коридорами доверия, финансовый риск (VaR, expected shortfall), надёжность оборудования, погодные ансамбли, планирование запасов.

Тяжёлые хвосты и bimodal-распределения. ℓ_2-регрессия стягивает прогноз к условному среднему и катастрофически проваливается на bursty / spike / regime-change-рядах, где истинное $p(X_t \mid \text{ctx})$ бимодально («прыжок вверх или вниз, не между»). Категориальная голова моделирует это напрямую. Кандидатные домены: сетевой трафик, высокочастотные финансы (CDS, дисбалансы стакана), промышленные сенсоры с режимами отказов.

Foundation zero-/few-shot прогнозирование. LM-рецепт тривиально переносится: один предварительно обученный на миллионе разнородных рядов, few-shot на новом. Так работают Chronos, TimesFM, MOIRAI. Наш токенизационный контракт (два замкнутых закона масштабирования) теоретически строже их схем бининга, что — вероятно — преимущество на масштабе.

Гетерогенные / многомасштабные ряды в одной модели. Энкодер самонормируется поканально по D, что позволяет одному набору весов обрабатывать μV ЭКГ, m/s^2 сейсмограммы и долларовую макроэкономику в одном обучении. Регрессионные базовые модели требуют поканальных голов или ручной унификации. Для foundation-моделей это ключевая проблема, и наша схема структурно проще.

Обнаружение аномалий через условное правдоподобие. Значение $-\log p(\text{token}_t \mid \text{ctx})$ доступно бесплатно на каждом шаге и корректно калибруется при переменной условной дисперсии. Регрессионные подходы опираются на $\|y_t - \hat{y}_t\|$, что плохо калибруется на гетероскедастичных рядах. Кандидатные домены: промышленный мониторинг, обнаружение сетевых вторжений, клинический мониторинг.

Условная и контрфактическая генерация. «А что, если X_t вырастет на Δ через неделю?» сводится к подмене токенов в префиксе с последующим продолжением генерации. Регрессионные модели требуют отдельного условного режима или структурного механизма ковариатов.

Вывод на периферии (edge). Модель из 130k параметров даёт результаты раздела 5; основная индуктивная сила лежит в токенизации, а не в весах. Это делает реалистичным subcpu-инференс на IoT и embedded-устройствах — режим, в котором современный Transformer-SOTA обычно не помещается.

Где архитектура не победит. Детерминированные MSE-бенчмарки на длинных горизонтах (ETTh1 / Traffic при pred_len ≥ 336) структурно невыгодны: one-shot инвертированные трансформеры выдают весь горизонт без авторегрессионной компаундации ошибки, а предл. 5 гарантирует рост нашей ошибки как H^{k-1}. Детерминированное долгосрочное прогнозирование — не наша цель; целью являются пункты выше.

8 Заключение

Decoder-only трансформер, авторегрессионно обучаемый на токенах производных с MASH-квантованием, достигает конкурентных результатов в краткосрочном и долгосрочном прогнозировании без специализированной головы. Токенизационный контракт даёт два замкнутых закона масштабирования словаря, справедливых при любом порядке производной; усиление ошибки предсказания даёт принципиальную причину предпочитать $k = 1$ для прогнозирования, несмотря на точную оценку реконструкции MASH при высших порядках. Порядковая мягкая кросс-энтропия согласована с естественной геометрией по бинам и приносит относительное улучшение sMAPE на 6% на M4 Hourly без изменения архитектуры.

Список литературы

[1] Liu, Y. et al. *iTransformer: Inverted Transformers are Effective for Time Series Forecasting.* ICLR 2024. arXiv:2310.06625.

[2] Nie, Y. et al. *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers.* ICLR 2023.

[3] Szegedy, C. et al. *Rethinking the Inception Architecture for Computer Vision.* CVPR 2016.

[4] Cao, W., Mirjalili, V., Raschka, S. *Rank- consistent Ordinal Regression for Neural Networks with Application to Age Estimation.* Pattern Recognition Letters 2020.

[5] Austin, J. et al. *Structured Denoising Diffusion Models in Discrete State-Spaces.* NeurIPS 2021.

[6] Candy, J.C., Temes, G.C. *Oversampling Delta- Sigma Data Converters.* IEEE Press 1992.

[7] Hayashi, T., Kaneko, Y., Morimoto, A., Sugawara, T., Iwasaki, K. *A multistage delta-sigma modulator without double integration loop.* IEEE ISSCC 1986.